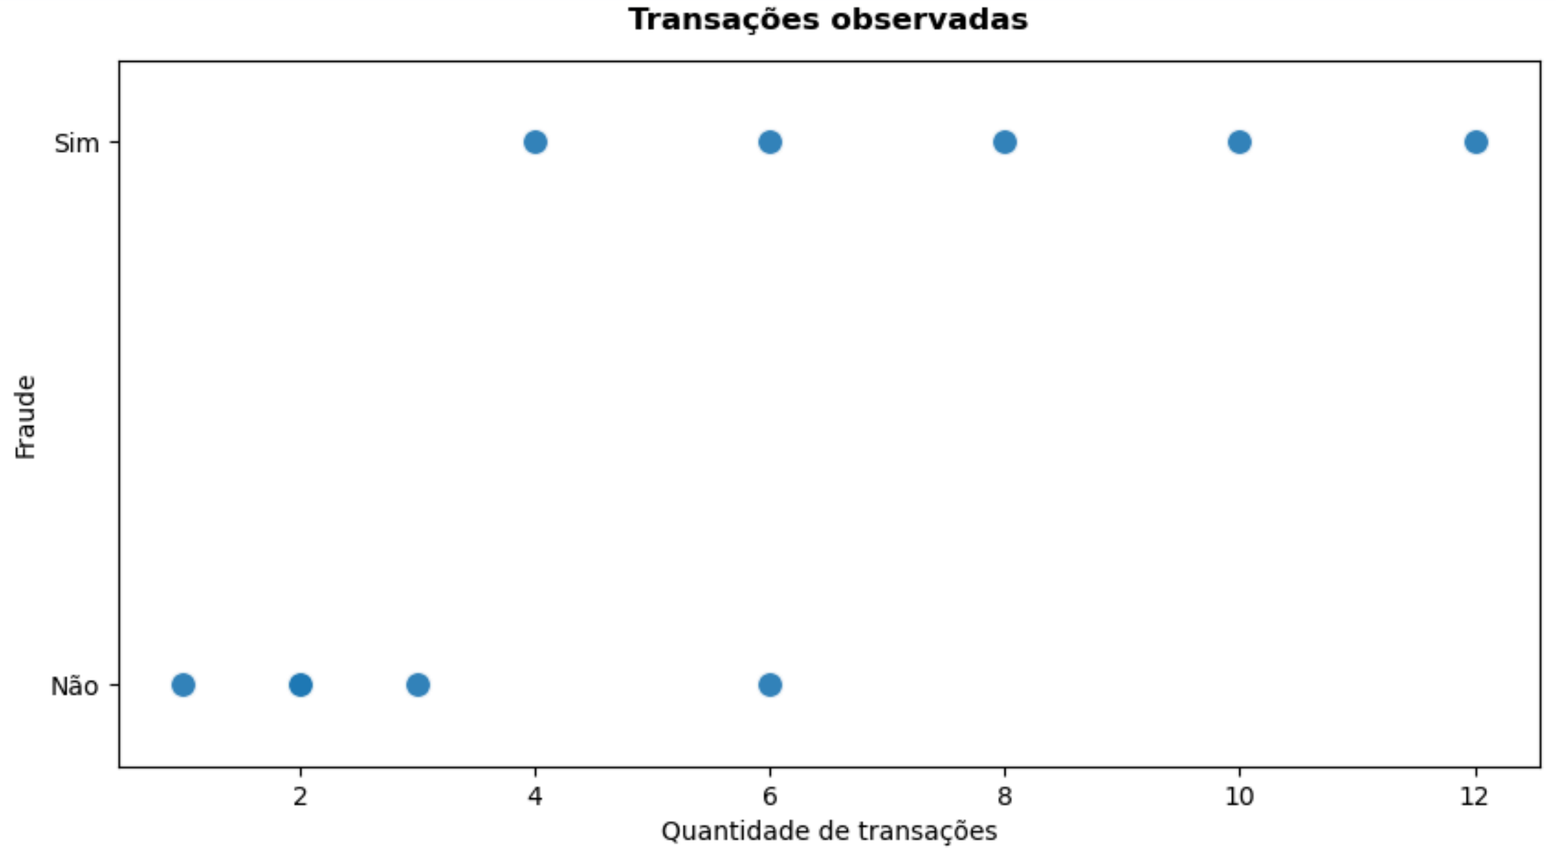
CURSO DE CIÊNCIA DE DADOS • AULA 02

Classificação e Regressão Logística

Previsão de variáveis qualitativas, função sigmoide, teoria da informação e entropia cruzada binária.

CENÁRIO BANCÁRIO • VISUALIZAÇÃO DOS DADOS

Dados de média de transações semanais por variavel categórica de fraude.



BLOCO TEÓRICO • ESCOPO DOS DADOS

Regressão Linear vs. Classificação

Regressão Linear

Variável Alvo: Valores quantitativos contínuos.

Domínio Matemático: Intervalo aberto de −∞ a +∞.

Aplicação Típica: Estimativa de emissões ou preços.

Modelos de Classificação

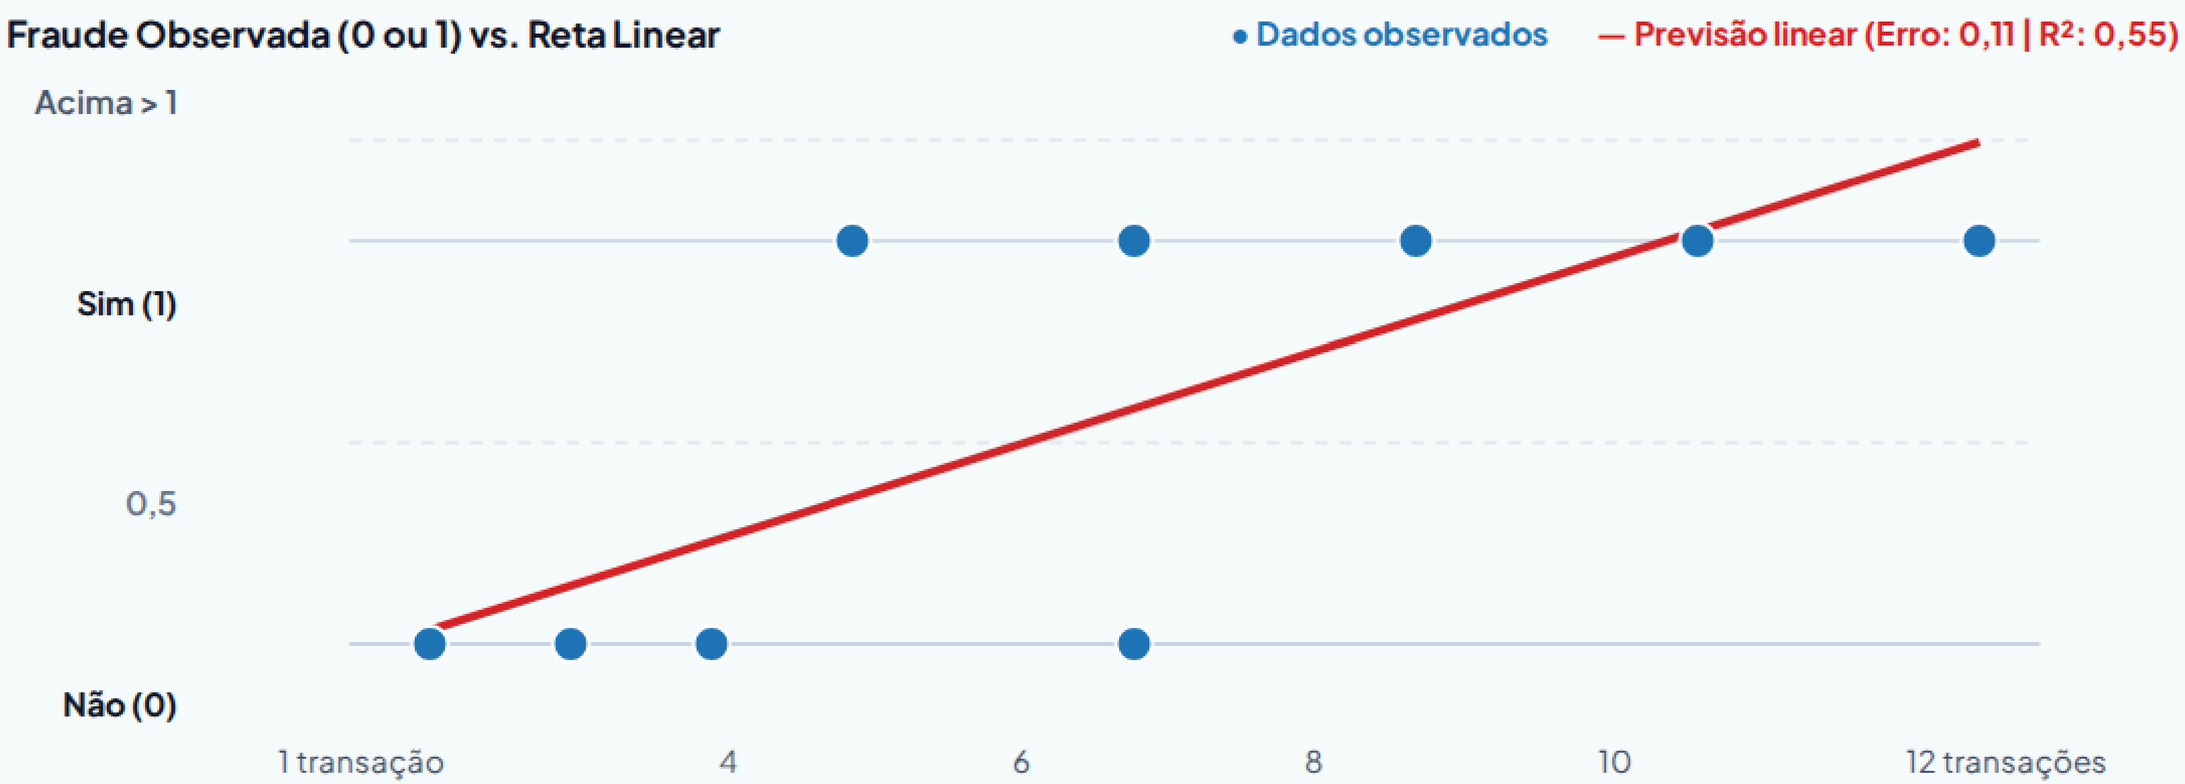
Variável Alvo: Categorias qualitativas discretas.

Saída Binária: Normal (0) contra Fraude (1).

Multiclasse: Categoria de veículo ou diagnóstico.

CENÁRIO BANCÁRIO • TENTATIVA LINEAR

Regressão Linear sobre Transações Semanais



Falha estrutural: o modelo prevê valores maiores que 1 para clientes acima de 10 transações.

SENSIBILIDADE A VALORES EXTREMOS • OUTLIER (X = 44)

Regressão Linear com Observação Extrema

NOVO ERRO (MSE)

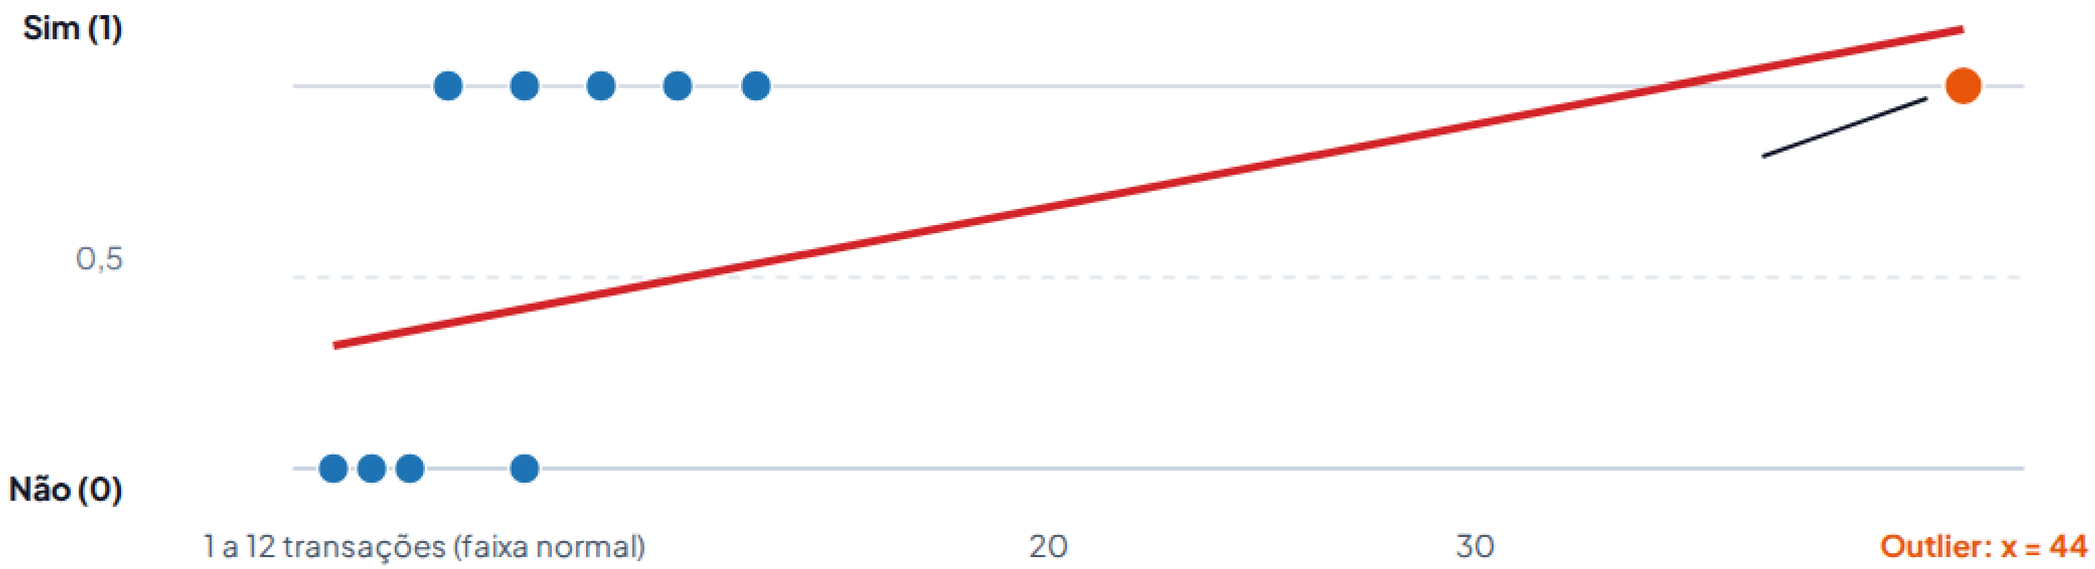
0,19 (subiu de 0,11)

APRENDIZADO (R^2)

0,23 (caiu de 0,55)

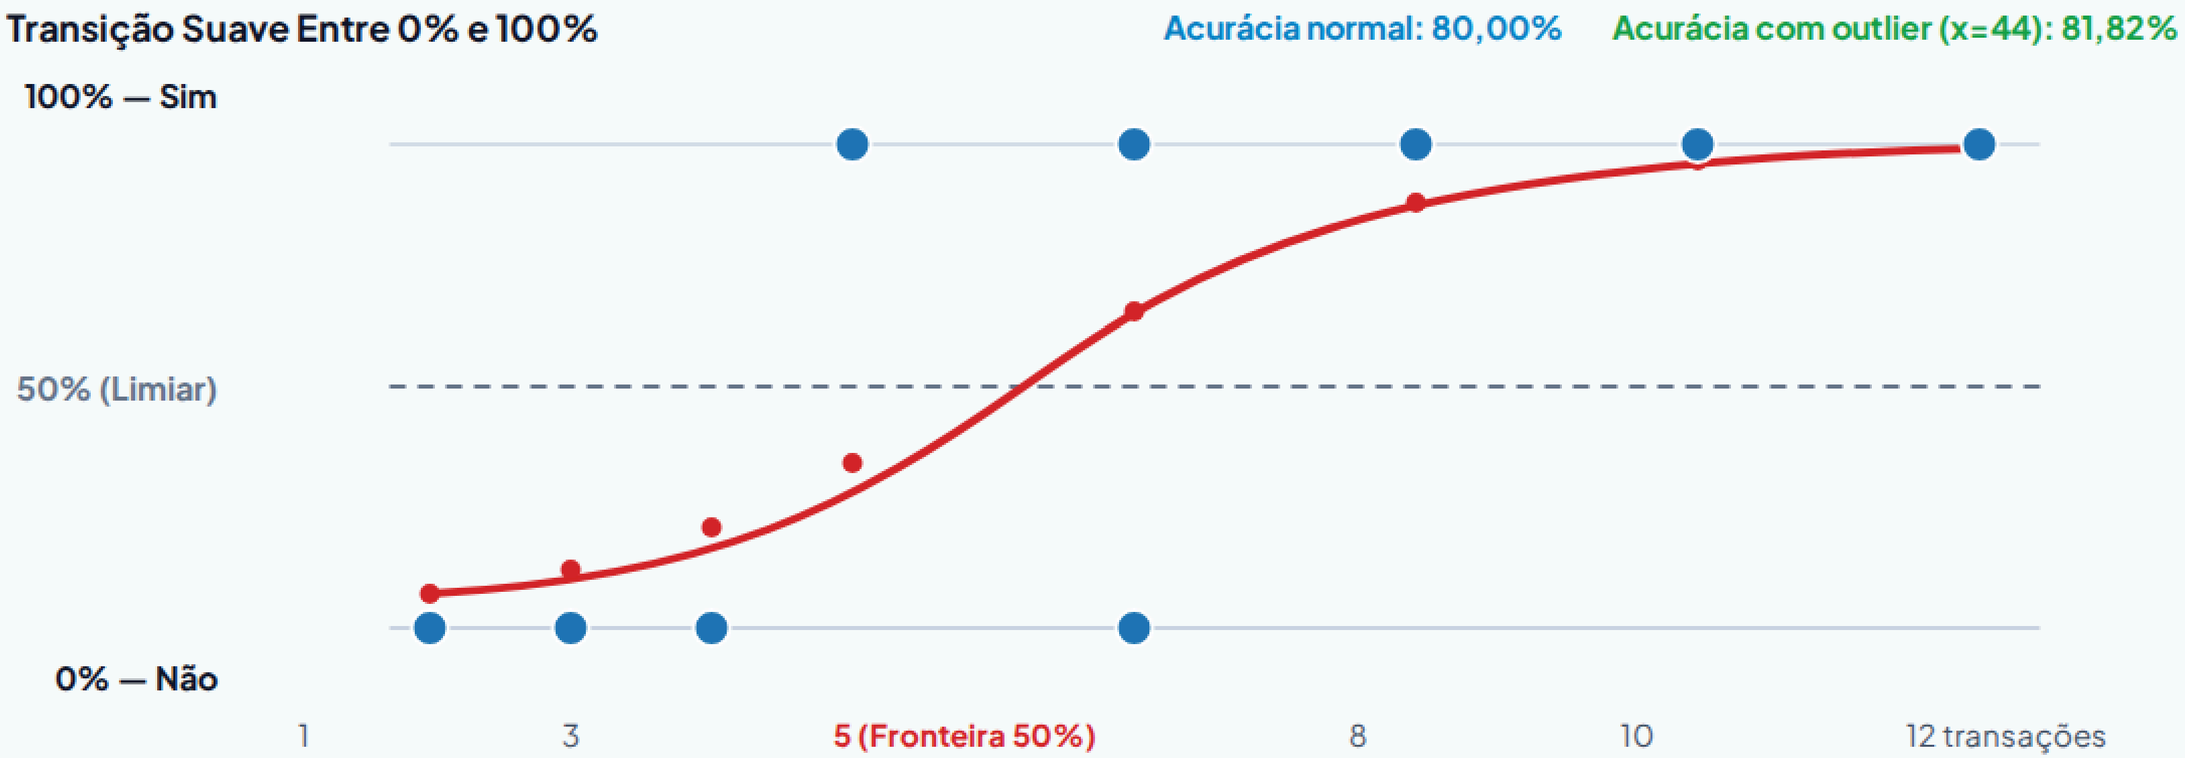
OBSERVAÇÃO EXTREMA

x = 44 transações



REGRESSÃO LOGÍSTICA • CURVA EM FORMATO DE S

Probabilidade Estimada com Curva Sigmoide



A sigmoide limita as saídas entre 0 e 1 e permanece estável mesmo com observações extremas.

FUNDAMENTOS MATEMÁTICOS • FUNÇÃO DE ATIVAÇÃO

Como a Função Sigmoide Calcula Probabilidades

FÓRMULA DA SIGMOIDE

$$PY = 1 \mid X = \sigma z = \frac{1}{1 + e^{-z}}$$

Combinação Linear: z = WX + b

Constante de Euler: e ≈ 2,718

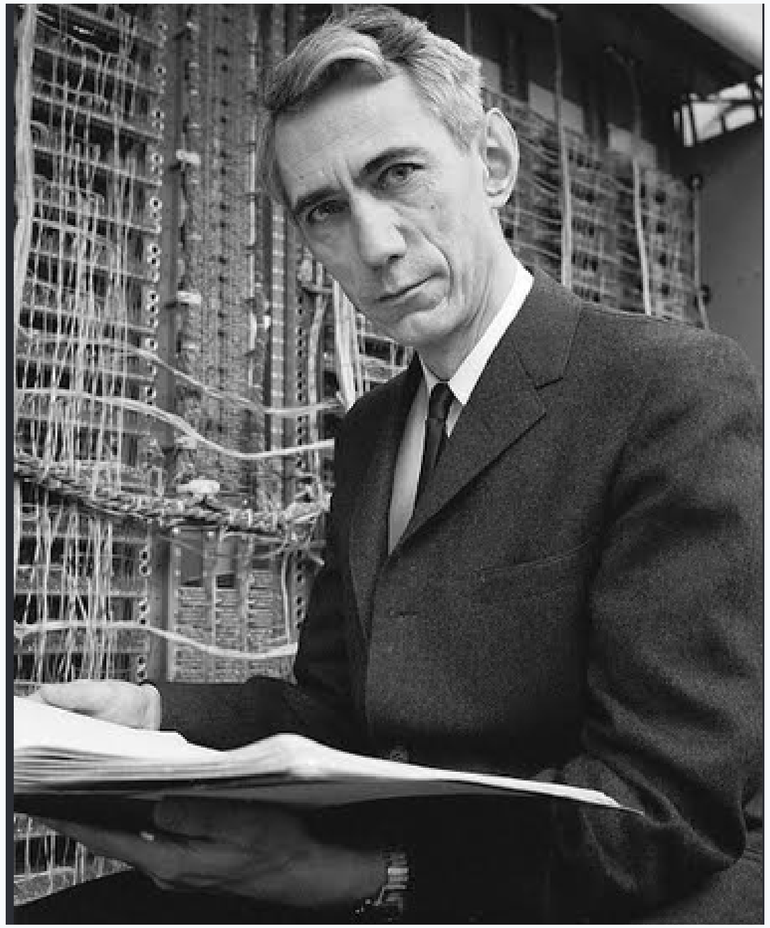
Limiar Padrão: z ≥ 0 equivale a P ≥ 50%

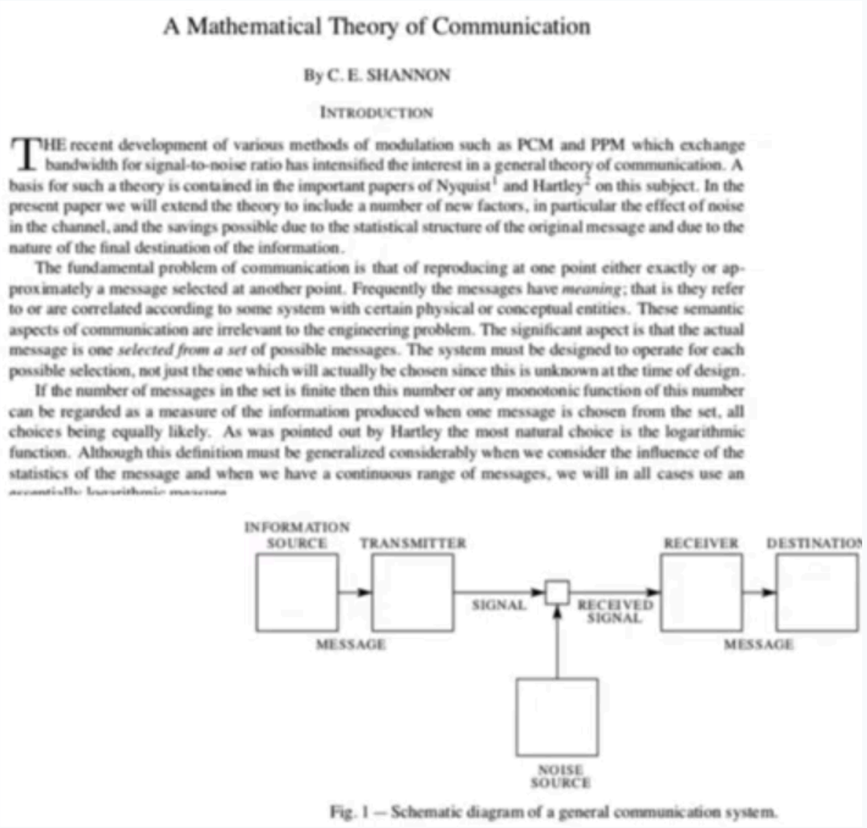
EXEMPLO NUMÉRICO (W = 0,5 | b = −3 | X = 2)

RESOLVER NO CÓDIGO

TEORIA DA INFORMAÇÃO • ORIGEM HISTÓRICA (1948)

Claude Shannon e a Quantificação da Incerteza





A Mathematical Theory of Communication

By C. E. SHANNON

INTRODUCTION

THE recent development of various methods of modulation such as PCM and PPM which exchange bandwidth for signal-to-noise ratio has intensified the interest in a general theory of communication. A basis for such a theory is contained in the important papers of Nyquist[1] and Hartley[2] on this subject. In the present paper we will extend the theory to include a number of new factors, in particular the effect of noise in the channel, and the savings possible due to the statistical structure of the original message and due to the nature of the final destination of the information.

The fundamental problem of communication is that of reproducing at one point either exactly or approximately a message selected at another point. Frequently the messages have *meaning*; that is they refer to or are correlated according to some system with certain physical or conceptual entities. These semantic aspects of communication are irrelevant to the engineering problem. The significant aspect is that the actual message is one *selected from a set* of possible messages. The system must be designed to operate for each possible selection, not just the one which will actually be chosen since this is unknown at the time of design.

If the number of messages in the set is finite then this number or any monotonic function of this number can be regarded as a measure of the information produced when one message is chosen from the set, all choices being equally likely. As was pointed out by Hartley the most natural choice is the logarithmic function. Although this definition must be generalized considerably when we consider the influence of the statistics of the message and when we have a continuous range of messages, we will in all cases use an

Fig. 1 — Schematic diagram of a general communication system.

A Mathematical Theory of Communication (Bell System, 1948)

TEORIA DA INFORMAÇÃO • ORIGEM HISTÓRICA (1948)

Quantificação da Incerteza

O PROBLEMA CENTRAL (1948)

Transmitir mensagens com máxima eficiência em um canal.

CONCEITO DE INCERTEZA

Eventos improváveis carregam maior volume de informação.

IMPACTO EM MACHINE LEARNING

Base matemática para medir erro em probabilidades.

TEORIA DA INFORMAÇÃO • ESTRUTURA DOS TÓPICOS

Da Informação à Entropia Cruzada

INFORMAÇÃO

Quantifica a incerteza de um evento.

$$Ix = -\log Px$$

↓

ENTROPIA

Quantifica toda informação possível em uma variável.

$$Hx = -\sum_{i=1}^{n} Px_i \cdot \log Px_i$$

↓

ENTROPIA CRUZADA

Quantifica a entropia relativa entre duas distribuições.

$$Hp, q = -\sum_{x} Px \cdot \log Qx$$

PARTE 01 • MEDIDA DE UM EVENTO ISOLADO

Informação: Quantificando a Incerteza do Evento

REGRA DE SHANNON

Menor probabilidade exige maior informação para ocorrer.

FÓRMULA DO EVENTO

Logaritmo natural da chance

$$Ix = -\ln Px$$

FAVORITO (60%)

Corinthians

I(x) ≈ 0,51

Cálculo: −ln(0,60)

ZEBRA (20%)

Real Madrid

I(x) ≈ 1,60

Cálculo: −ln(0,20)

ZEBRA (20%)

Al Hilal

I(x) ≈ 1,60

Cálculo: −ln(0,20)

NULO (0%)

Palmeiras

I(x) → ∞

Evento impossível

PARTE 02 • MEDIDA GLOBAL DA VARIÁVEL

Entropia: Informação Média da Variável Completa

EVENTO VS. VARIÁVEL

Soma a informação de cada clube ponderada pela chance.

EQUAÇÃO GERAL

$$HX = -\sum_{i=1}^{n} px_i \, lnpx_i$$

PARCELA FAVORITO (60%)

−0,6 · ln(0,6) ≈ 0,31

Contribuição do Corinthians

PARCELA ZEBRAS (2 × 20%)

−0,4 · ln(0,2) ≈ 0,64

Real Madrid somado ao Al Hilal

ENTROPIA DA VARIÁVEL

H(X) ≈ 0,95

Informação média necessária

PARTE 03 • COMPARAÇÃO DE DISTRIBUIÇÕES

Entropia Cruzada: Casa de Apostas A vs. Casa B

0,95

Entropia Casa A — H(P)

Referência: 60% | 20% | 20%

0,38

Entropia Casa B — H(Q)

Estimada: 90% | 8% | 2%

1,35

Entropia Cruzada — H(P, Q)

Custo de divergência entre P e Q

$$HP\ ,\ Q = \ -\ \sum_{i=1}^{n} px_i\ lnqx_i\ =\ -\ 0{,}6ln0{,}9 + 0{,}2ln0{,}08 + 0{,}2ln0{,}02 \approx 1{,}35$$

Penaliza previsões Q distantes da referência real P.

APRENDIZADO DO MODELO • FUNÇÃO DE CUSTO BINÁRIA

Entropia Cruzada Binária (BCE)

$$BCE = -\frac{1}{N}\sum_{i=1}^{N} y_i \ln \hat{y}_i + 1 - y_i \ln 1 - \hat{y}_i$$

Caso Real y = 1 (ŷ = 0,1192)

Custo alto de 2,12 por erro grave.

Caso Real y = 0 (ŷ = 0,1192)

Custo baixo de 0,12 por acerto.

Otimização por Gradiente

Ajuste iterativo dos pesos W e b.

ESTUDO DE CASO PRÁTICO • DATASET DIAGNOSIS

Pipeline Real: Diagnóstico Clínico com 569 Amostras

ETAPA 01

Inspeção e Limpeza

Exclusão de identificadores e colunas vazias.

ETAPA 02

Codificação Alvo

Conversão de Maligno (0) e Benigno (1).

ETAPA 03

Escala e Treino

Padronização das 30 variáveis morfológicas.

ETAPA 04

Matriz de Confusão

Auditoria de acertos e falsos diagnósticos.

REVISÃO E PRÁTICA • AULA 02 COMPLETA

Hora de Praticar no Notebook!

Implemente as funções de informação e entropia, explore a dispersão de raio médio e avalie a matriz de confusão no conjunto de teste.

Image Sources



https://manhattanrarebooks.cdn.bibliopolis.com/pictures/2121.jpg?auto=webp&v=1533758123

Source: www.manhattanrarebooks.com