CURSO DE CIÊNCIA DE DADOS • AULA 01 COMPLETA (PARTE 1 & PARTE 2)

Dos Dados Brutos à Regressão Linear

Pipeline ETL, limpeza, engenharia de atributos, análise exploratória visual e fundamentos matemáticos de modelos preditivos.

PARTE 1 • INTRODUÇÃO

Os Três Pilares da Ciência de Dados



Matemática e Estatística

Modelagem formal de incertezas.



Computação e Código

Processamento escalável via algoritmos.



Conhecimento de Domínio

Hipóteses aplicadas ao negócio.

Analista de Dados vs. Cientista de Dados

Analista de Dados

Foco Temporal: Olha para eventos passados.

Pergunta Central: O que aconteceu no período?

Entregáveis: Painéis executivos e relatórios descritivos.

Cientista de Dados

Foco Temporal: Projeta cenários futuros.

Pergunta Central: O que acontecerá amanhã?

Entregáveis: Algoritmos preditivos e inferência.

BLOCO 01 • PREPARAÇÃO DE DADOS

Fluxo ETL, Limpeza, EDA e Engenharia de Atributos

Como estruturar tabelas confiáveis antes de aplicar qualquer modelo estatístico.

CONCEITO FUNDAMENTAL

Afinal, O Que São Dados?

Fatos Brutos

Registo de informações em qualquer lugar.

Onipresença Digital

Cliques rastreados a cada segundo.

Ativo Estratégico

Valor real exige contexto estruturado.

ESTATÍSTICAS GLOBAIS & ESTUDO IDC

A Explosão de Dados no Mundo

402,74M TB

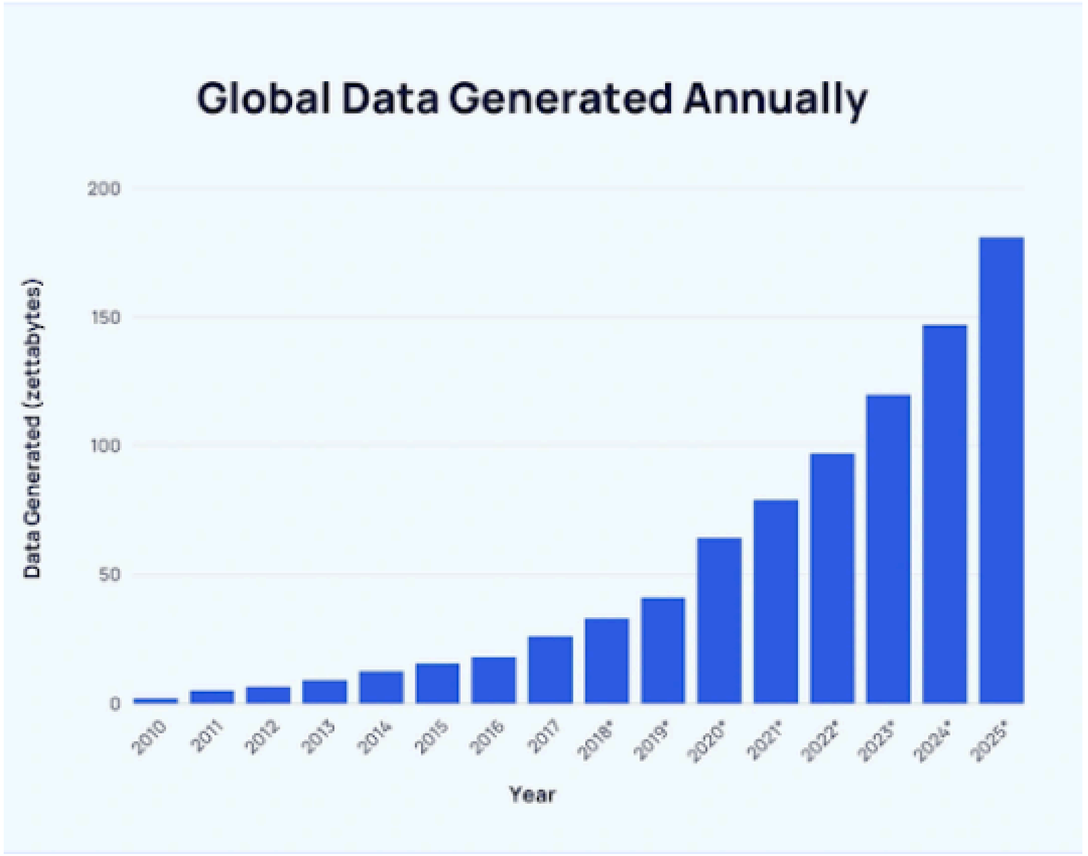
Volume criado a cada dia.

7 Petabytes/s

Taxa global por segundo (IDC).

~17B Livros/s

Equivalente escrito por segundo.



BLOCO 01 • ARQUITETURA DE DADOS

As Três Etapas do Processo ETL

01. EXTRACT

Extração

Coleta em CSVs ou bancos.

02. TRANSFORM

Transformação

Limpeza e novas variáveis.

03. LOAD

Carregamento

Base pronta para modelagem.

PREPARAÇÃO E INTEGRAÇÃO

O Fluxo ETL na Prática

EXEMPLO EM PYTHON (PANDAS)

```
# 1. Extract: leitura dos arquivos
df = pd.read_csv('FuelConsumptionCo2.csv')

# 2. Transform: limpeza e combinação
df_novo = pd.merge(df, tab_aux, on='MAKE')

# 3. Load: dataset pronto para análise
df_novo.head()
```

E

Extract (Extrair)

Obtenção via CSV, planilhas, SQL ou APIs.

T

Transform (Transformar)

Correção de tipos, ausências e junções.

L

Load (Carregar)

Destino final em DataFrame ou Data Warehouse.

BLOCO 01 • DATA CLEANING (PARTE TEÓRICA)

Por Que Limpar os Dados Antes de Analisar?

Valores Ausentes (NaN)

Quebram cálculos matriciais.

Linhas Duplicadas

Distorcem médias estatísticas.

Tipos Incorretos

Números lidos como texto.

BLOCO 01 • DATA CLEANING NO PANDAS

Comandos Essenciais de Limpeza

🚫 Dados Nulos (NaN, None, NaT)

Obstáculo: Quebram algoritmos nos modelos preditivos.

Detecção: Método **.isna()** mapeia registros vazios.

Preenchimento: Método **.fillna()** substitui ausências.

Exclusão: Método **.dropna()** remove linhas incompletas.

</> Divergência de Tipos (Object)

Causa: Símbolos monetários ou textos **"N/A"**.

Desempenho: Perda total da computação vetorizada.

Incompatibilidade: Modelos rejeitam colunas tipo **object**.

Conversão: Padronização numérica via **pd.to_numeric()**.

BLOCO 02 • ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

Estatísticas, Histograma, Boxplot e Correlações

Investigando distribuições, quartis, outliers e relações lineares entre variáveis.

BLOCO 02 • RESUMO ESTATÍSTICO

Visão Geral com df.describe()

Métrica	ENGINESIZE	CYLINDERS	CONSUMPTION_CITY	CONSUMPTION_COMB	CO2EMISSIONS
mean (Média)	3,35 L	5,79	13,30 L/100km	11,58 L/100km	256,23 g/km
std (Desvio)	1,42 L	1,80	4,10 L/100km	3,49 L/100km	63,37 g/km
min / 25% (Q1)	1,00 / 2,00	3,00 / 4,00	4,60 / 10,25	4,70 / 9,00	108,00 / 207,00
50% (Mediana)	3,40 L	6,00	12,60 L/100km	10,90 L/100km	251,00 g/km
75% (Q3) / max	4,30 / 8,40	8,00 / 12,00	15,55 / 30,20	13,35 / 25,80	294,00 / 488,00

BLOCO 02 • MEDIDAS DE POSIÇÃO E DISPERSÃO

Quartis e Intervalo Interquartil (IQR)

207

1º Quartil (Q1 – 25%)

25% emitem até 207 g/km

251

Mediana (Q2 – 50%)

Centro exato da amostra

294

3º Quartil (Q3 – 75%)

75% emitem até 294 g/km

87

IQR (Q3 – Q1)

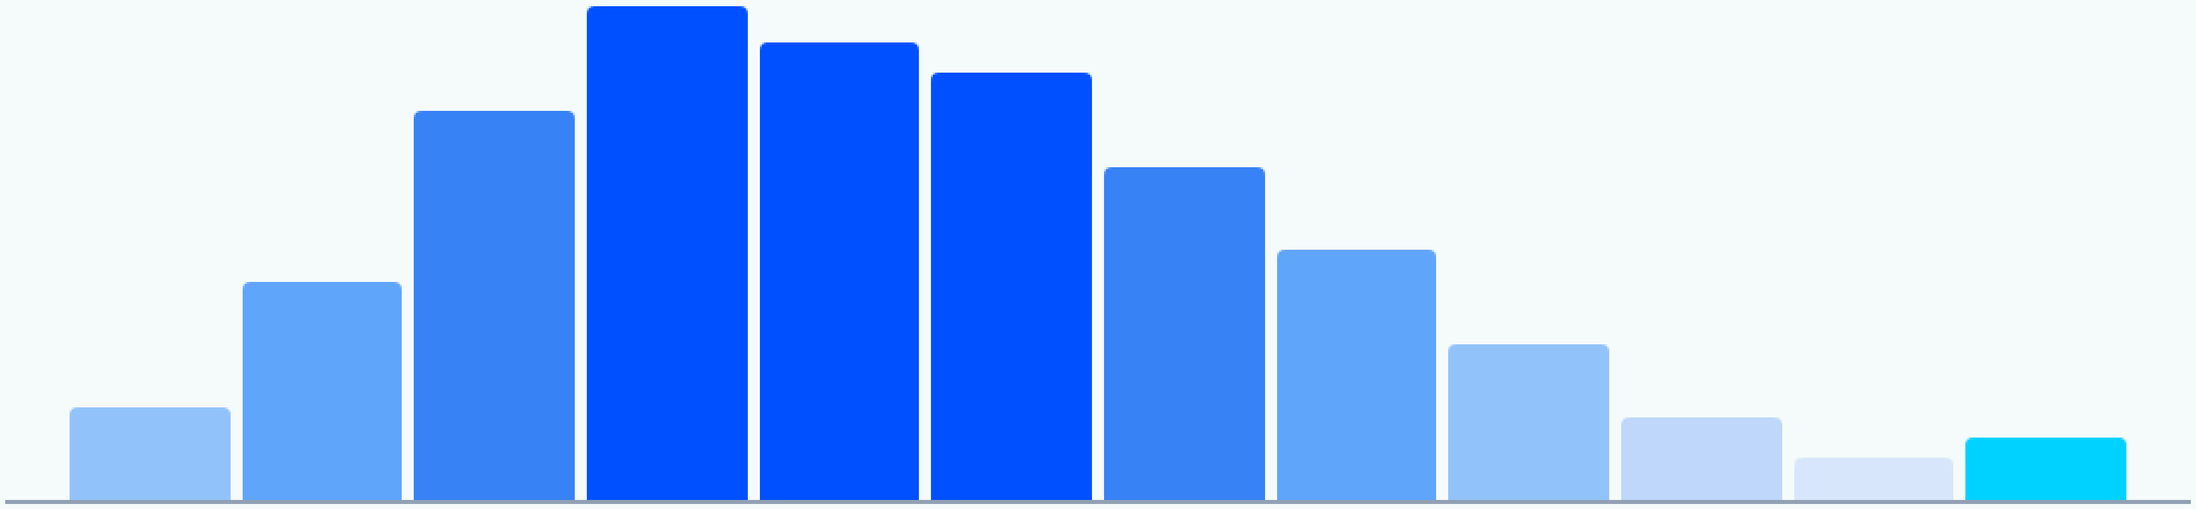
Amplitude dos 50% centrais

Critério de Outlier Superior: Q3 + 1,5 × IQR = 294 + 130,5 = 424,5 g/km

Acima de 424,5 g/km → Outlier

VISUALIZAÇÃO DE DISTRIBUIÇÃO • SNS.HISTPLOT(KDE=TRUE)

Histograma: Frequência e Densidade



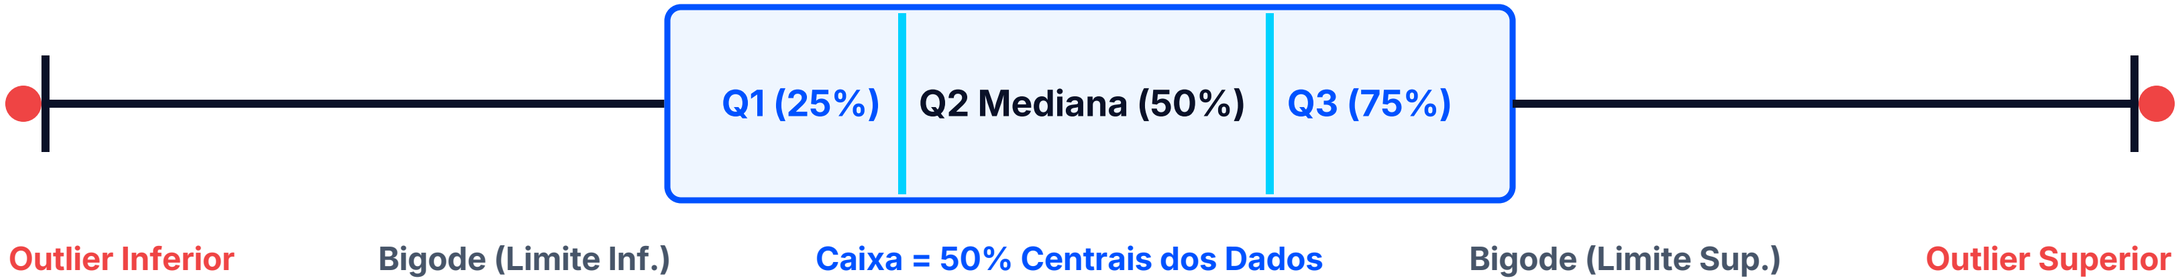
Intervalos (Bins): Barras contínuas medem concentração.

Assimetria e Caudas: Revelam desvios da média.

Picos Isolados: Sinalizam possíveis outliers.

QUARTIS, DISPERSÃO E LIMITES • SNS.BOXPLOT()

Boxplot e Detecção de Outliers (IQR)



INTERVALO INTERQUARTIL

$$IQR = Q3 - Q1$$

LIMITE INFERIOR

$$Q1 - 1{,}5 \times IQR$$

LIMITE SUPERIOR

$$Q3 + 1{,}5 \times IQR$$

BLOCO 02 • MAPA DE CALOR (HEATMAP)

Correlação de Pearson com CO2EMISSIONS

+0,89

FUELCONSUMPTION_COMB

Forte tendência positiva

+0,87

ENGINESIZE

Motor maior emite mais

+0,85

CYLINDERS

Acompanha tamanho do motor

-0,91

COMB_MPG

Relação inversa (milhas/galão)

Regra de Ouro: Correlação varia de −1 a +1 e mede alinhamento linear; não confirma causa e efeito.

BLOCO 01 • ENGENHARIA DE ATRIBUTOS

O Que É Feature Engineering?

Dados → Atributos

Criar ou transformar colunas para destacar padrões matemáticos invisíveis na tabela original.

PARTE 2 • FUNDAMENTOS DE MODELAGEM PREDITIVA

Linearidade, Função de Custo MSE, Derivada e Regressão Linear

Como a máquina aprende a melhor reta preditiva minimizando erros matematicamente.

PARTE 2 • APRENDIZADO SUPERVISIONADO

Diferença Entre Regressão e Classificação

Regressão

Variável Alvo: Número real contínuo.

Objetivo Geométrico: Traçar reta ou curva sobre os pontos.

Exemplo na Aula: Prever gramas de CO_2 por km.

Classificação

Variável Alvo: Rótulo ou classe discreta.

Objetivo Geométrico: Separar grupos por fronteira.

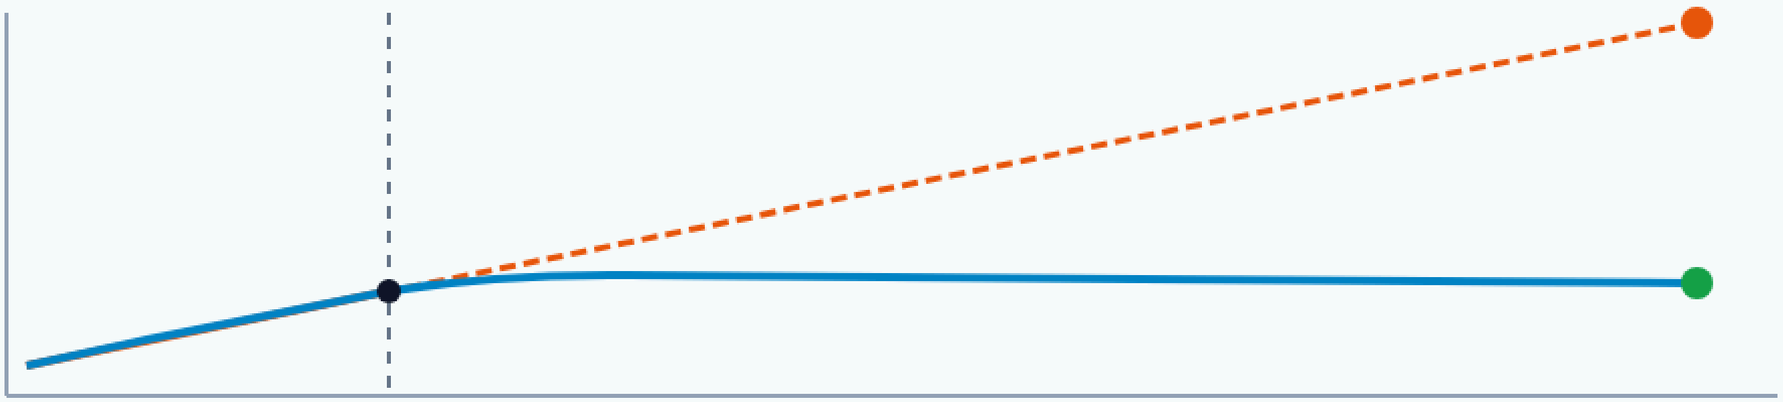
Exemplo na Aula: Separar veículo econômico vs. gastador.

PARTE 2 • QUANDO A LINEARIDADE FALHA (DATASET NHANES)

Idade vs. Altura: Linear na Infância, Estável no Adulto

Reta Ajustada até 15 Anos vs. Comportamento Biológico Real até 80 Anos

Corte de Treino: Age ≤ 15 anos



Observação: Até 15 anos a reta acompanha os dados; após 18 anos a altura estabiliza e a reta diverge drasticamente.

PARTE 2 • ALERTA DE MODELAGEM

O Absurdo Biológico da Extrapolação Linear

566 cm vs. 160 cm

Aos 80 anos, a reta treinada apenas em crianças prevê 5,66 metros de altura, contra 1,60 metro da mediana real.

PARTE 2 • CONCEITO DE LINEARIDADE

A Equação Fundamental da Reta

MODELO UNIDIMENSIONAL

$$\hat{y} = ax + b$$

Variável Independente (x): Atributo de entrada conhecido.

Inclinação / Peso (a): Quanto y varia para cada unidade de x.

Intercepto / Viés (b): Valor base quando x = 0.

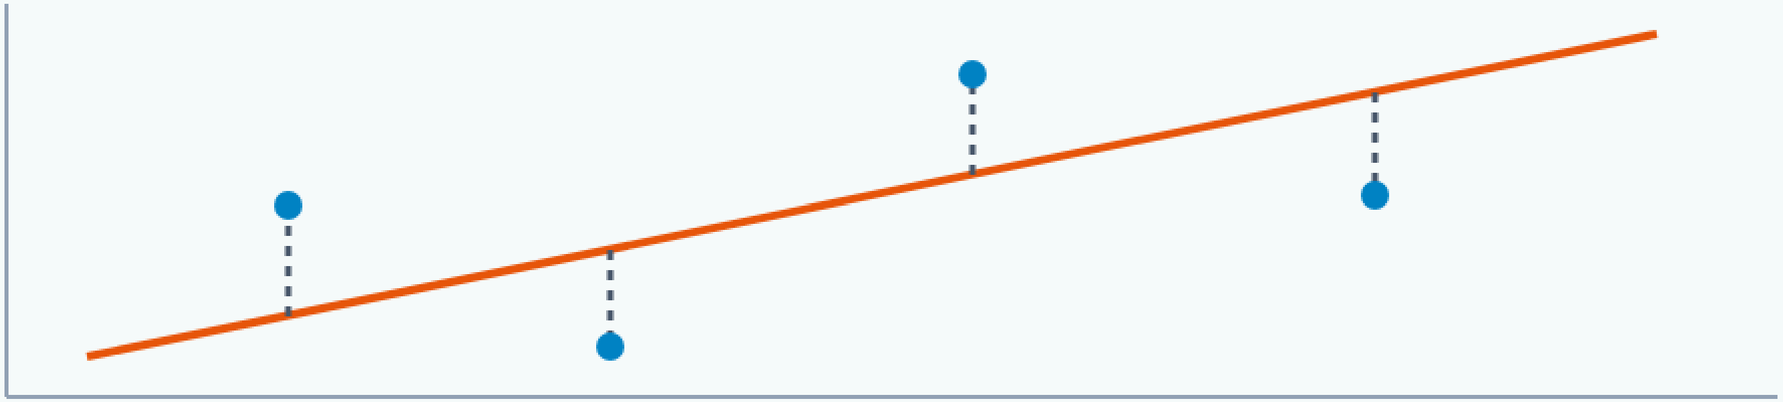
Premissa Linear: Taxa de crescimento constante em todo o domínio.

PARTE 2 • GEOMETRIA DO ERRO

Como Medir a Qualidade da Reta? Os Resíduos

Distância Vertical Entre o Valor Real Observado (y_i) e a Predição na Reta ($\hat{y}_i$)

Erro Individual = $y_i - \hat{y}_i$



Problema da Soma Simples: Pontos acima da reta têm erro positivo e pontos abaixo têm erro negativo, anulando-se.

PARTE 2 • FUNÇÃO DE CUSTO (LOSS FUNCTION)

Erro Médio Quadrático (Mean Squared Error - MSE)

FÓRMULA DO MSE

$$MSE = \frac{1}{n} \sum_{i=1}^{n} y_i - \hat{y}_i^{\,2}$$

Por Que Elevar ao Quadrado? Elimina sinais negativos de resíduos.

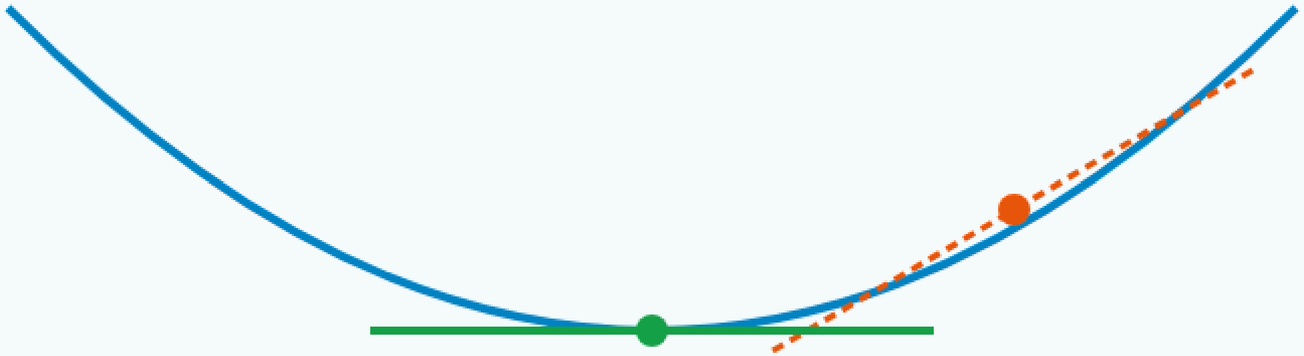
Penalização Severa: Erros grandes pesam muito mais no custo total.

Curva Diferenciável: Forma uma parábola suave ideal para cálculo de derivadas.

Intuição Geométrica da Derivada em f(x) = x²

Da Reta Secante (Δx Grande) até a Reta Tangente no Ponto Mínimo (Derivada = 0)

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$



Direção do Ajuste: A inclinação da reta tangente aponta para onde diminuir o erro até atingir inclinação zero no fundo do vale.

PARTE 2 • TREINAMENTO DO MODELO

Como o Algoritmo Encontra a Melhor Reta

PASSO 01

Cálculo do Erro

Mede o MSE da reta atual.

PASSO 02

Cálculo do Gradiente

Obtém a derivada de a e b.

PASSO 03

Mínimo Global

Estabiliza onde a derivada é zero.

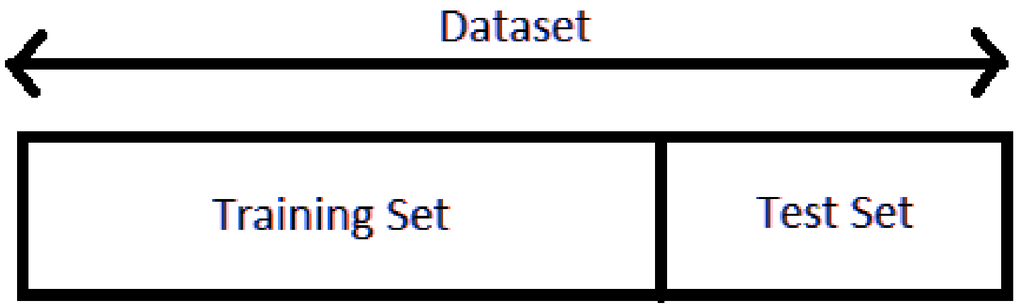
PARTE 2 • IMPLEMENTAÇÃO EM PYTHON

Divisão Treino vs. Teste no Scikit-Learn

Por Que Separar? Avaliar generalização em dados inéditos.

Divisão 80/20: 80% ajustam pesos; 20% auditam o erro real.

Treinamento: model.fit(X_train, y_train) calcula a reta.



PARTE 2 • RESULTADOS NO CONJUNTO DE TESTE

Métricas Finais: MAE, RMSE e R² Score

16,69

MAE (g/km)

Erro médio absoluto direto

22,61

RMSE (g/km)

Raiz do MSE na mesma escala

0,876

R² Score (87,6%)

Variância explicada pelo modelo

Interpretação do R²: R² = 0 equivale a chutar a média simples; R² = 0,876 comprova alto poder preditivo.

REVISÃO E PRÓXIMOS PASSOS • AULA 01 COMPLETA

Hora de Praticar nos Notebooks!

Execute as células da Parte 1 e da Parte 2, experimente novas features no modelo e compare o impacto nas métricas MAE, RMSE e R^2.